


```
df_baby.head()
```

```
[2]:
```

	Time	Gender	Weight	Mins
0	5	1	3837	5
1	104	1	3334	64
2	118	2	3554	78
3	155	2	3838	115
4	257	2	3625	177

```
[3]: # Dimensiones  
df_baby.shape
```

Gender



$X = \# \text{ de fallos hasta 1 éxito}$

$$P(X=k) = q^{k-1} p$$

$x \rightarrow 1, 2, \dots, \infty$

$1-p = q \rightarrow \text{prob. de fallo}$

$p \rightarrow \text{prob de éxito}$

Dist.
Geométrica
Discretas

$X \rightarrow \# \text{ de éxitos}$
 $\text{en } n \text{ eventos}$

$$P(X=k) = {}_n C_k p^k q^{n-k}$$

$X \rightarrow 0, 1, 2, \dots, n$

Dist. Binomial
Discrete


```
2    26  
dtype: int64
```

Observamos que tenemos 26 nacimientos de niños. Lo que sigue es ver si esta cifra es consistente con una distribución binomial teórica. Para crear esta distribución binomial teórica suponemos $n = 44$ número de nacimientos y $p = 0.5$.

```
• [14]: #dist = st.binom(n=44, p=0.5)  
  
dist = st.norm(loc=, scale=)  
  
dist.
```

$$P(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$


$= N(\mu, \sigma)$

```
[13]: dist_binom = st.binom(n=44, p=0.5) # instanciamos la distribucion y sus parám  
  
x_tries = np.arange(0,45,1)# variable aleatoria, número de casos de éxito  
x_cdf = np.arange(0,27,1) ## rango de la distribución acumulada, hasta x=26  
  
fig = plt.figure(figsize=(10,5))  
  
# Primera figura
```

```

dist = st.norm(loc=20, scale=2)
# ecuacion P(x)
x = np.arange(10,30,0.1)
P_x = dist.pdf(x)
plt.plot(x,P_x)
plt.show()

```



$$P(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$$\int_{-1\sigma}^{1\sigma} P(x) dx = P$$

```

[13]: dist_binom = st.binom(n=44, p=0.5) # instanciamos la distribucion y sus parámetros

```

```

x_tries = np.arange(0,45,1) # variable aleatoria, número de casos de éxito
x_cdf = np.arange(0,27,1) ## rango de la distribución acumulada, hasta x=26

```

```
# ecuacion P(x)
```




```
x = np.arange(10,30,0.1)
```

```
P_x = dist.pdf(x)
```


```
plt.plot(x,P_x)
```

```
plt.show()
```

```
print(dist.cdf
```



```
plt.show()
```



$$P(X=k) = {}_n C_k p^k q^{n-k}$$

$n = \text{fijo}$

/ intervalo de tiempo

$\lim_{n \rightarrow \infty}$

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Discreto

$X \rightarrow$

de ocurrencias

/ intervalo

lar.


Función de densidad (PDF)

$$f(t) = \lambda e^{-\lambda t}$$

para $t \geq 0$.

Propiedades ¶

- Media:
- Varianza:



Creamos los intervalos temporales

```
interarrival_times = df_baby['Mins'].diff().dropna() # primera diferencia
```

estimamos el parámetro λ como $\lambda = \frac{1}{\mu}$, donde la media μ es la media de estas diferencias temporales.




Gráfico Q-Q (Quantile-Quantile Plot)

El **gráfico Q-Q** (Quantile-Quantile) es una herramienta visual que nos permite evaluar si un conjunto de datos sigue una distribución teórica determinada, como la normal. Funciona comparando los **cuantiles observados** en los datos con los **cuantiles esperados** bajo la distribución teórica. Si los puntos del gráfico se alinean aproximadamente a lo largo de una línea recta (usualmente la diagonal), podemos concluir que los datos siguen razonablemente bien dicha distribución. En nuestro caso, utilizaremos el gráfico Q-Q para examinar si los pesos al nacer de los bebés se ajustan a una **distribución normal**. Esta visualización complementa otras pruebas estadísticas y nos brinda una forma intuitiva de detectar posibles desviaciones, como asimetría o colas pesadas.

Prueba de Normalidad de Shapiro-Wilk

Además del gráfico Q-Q, también aplicaremos una prueba estadística formal para evaluar si los datos siguen una distribución normal: la **prueba de Shapiro-Wilk**. Esta prueba es ampliamente utilizada debido a su buena potencia para detectar desviaciones de la normalidad, especialmente en muestras pequeñas o moderadas.

La prueba contrasta las siguientes hipótesis:


- **Hipótesis nula (H_0):** los datos provienen de una distribución normal.
- **Hipótesis alternativa (H_1):** los datos **no** provienen de una distribución normal.

El resultado de la prueba incluye un **estadístico de prueba** y un **valor-p**. Si el valor-p es menor que un umbral predefinido (usualmente 0.05), se **rechaza la hipótesis nula**, lo que indica que los datos muestran evidencia suficiente para concluir que **no se distribuyen normalmente**. En nuestro caso, aplicaremos esta prueba a los pesos al nacer para complementar el análisis visual y tomar una decisión más robusta sobre la adecuación de la distribución normal.



```
[23]: ## Q-Q plot con scipy.stats
st.probplot(df_baby['Weight'],
            dist='norm',
            plot=plt)

plt.show()

# Escogemos nivel de significancia para las pruebas de hipótesis.
```



$$X = \{x_1, x_2, \dots, x_n\}$$



Prueba de hipótesis



Overview

- Redactar la hipótesis nula H_0 y alternativa H_1 según lo que se pretende analizar.
- Decidir un nivel de **significancia** para la prueba.
- Realizar un experimento. Recolectar información de una **muestra** de datos.
- Calcular una **estadística de prueba** según el modelo utilizado.


Suppose
 $\sigma = 2$ $n = 50$

$H_0: \mu = 20$
 $H_1: \mu \neq 20$

$\bar{X}$ → Teorema del
 limite central



H_1



H_1 : La distribución no es normal,

o más formalmente aún:

$H_0 : X \sim \mathcal{N}(\mu, \sigma^2)$ *Si es normal*

→ $H_1 : X \not\sim \mathcal{N}(\mu, \sigma^2)$. *no es normal*

Ahora el test Shapiro-Wilks intenta rechazar la hipótesis nula a no
realizar el test usamos la función `shapiro.test` en R:

Ejemplo 7.3 (Test de Shapiro Wilks en R)



estadístico de pruebas

Theoretical quantiles

Prueba de Shapiro-Wilk

estadístico $W=0.899$, $p\text{-valor}=0.001$

Probablemente no es gaussiano

Elige usuario

$\alpha = 0.1, 0.05, 0.01$

$p\text{-valor} > \alpha \longrightarrow$ No se rechaza H_0

$p\text{-valor} < \alpha \longrightarrow$ Se rechaza H_0

No depende de los datos

Resumen y Conclusiones

Este notebook nos permitió dar un primer paso fundamental: **explorar y enter**

