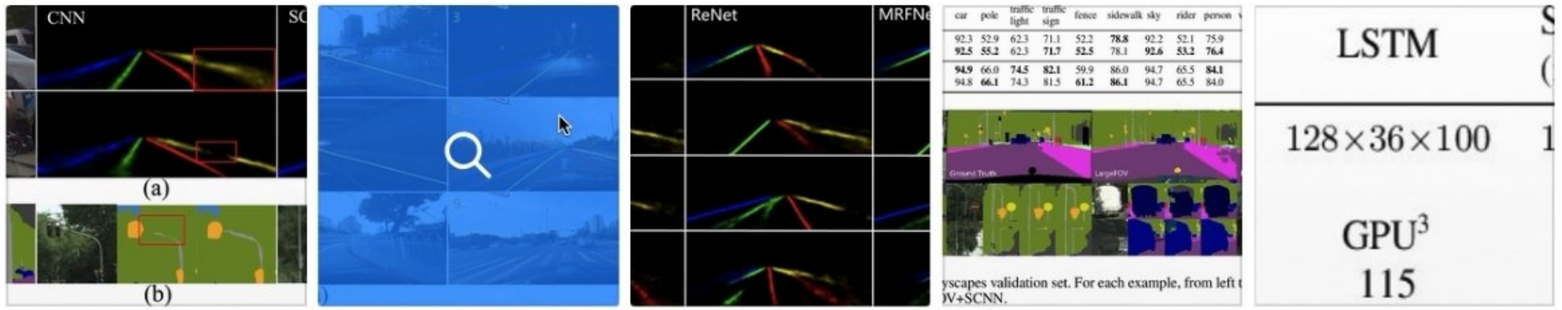
[PDF] Online L | The cosmic ac | Frontiers | The | The high energy X | Joint-instrume | astrometry-inf | Matemáticas A | marimo | 09_pytorch_cr | IvTole/Topicos_ | `num_features | lenet 1998 - B | cnn road detec | Comparison | Lane Detectio
www.researchgate.net/figure/Comparison-between-probmaps-of-baseline-ReNet-MRFNet-ResNet-101-and-SCNN_fig3_321902196
VPN

Source publication



Spatial as Deep: Spatial CNN for Traffic Scene Understanding

Article | Full-text available | Apr 2018

Xingang Pan · Jianping Shi · Ping Luo · [...] · Xiaoou Tang

Convolutional neural networks (CNNs) are usually built by stacking convolutional operations layer-by-layer. Although CNN has shown strong capability to extract semantics from raw pixels, its capacity to capture spatial relationships of pixels across rows and columns of an image is not fully explored. These relationships are important to learn seman...

Cite | Download full-text

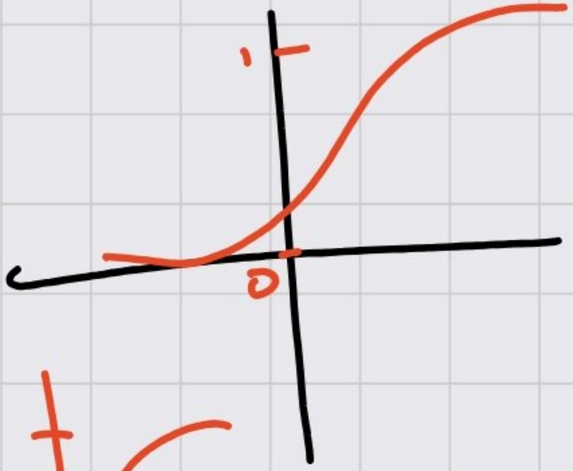
Contexts in source publication

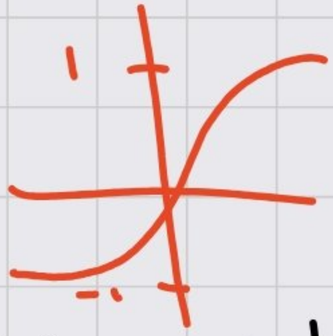
Adobe Ac
Trabajos d
con un Asist
Aplica
Pruébal
10%
¿En qué puedo ay
Crear infografía
Analista

www.researchgate.net/figure/a-Dataset-examples-for-different-scenarios-b-Proportion-of-each-scenario_fig1_321902196

- Unidad 3 → Álgebra Lineal.

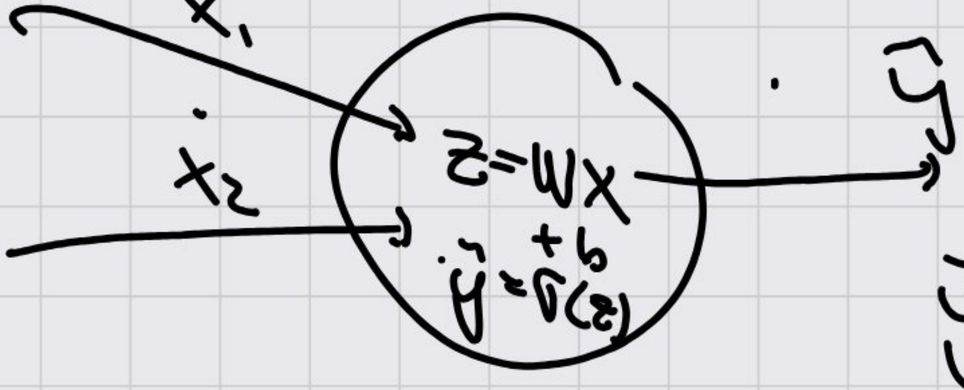
> Vectores
> Sist. de Ecs. Lineales
  . Gauss-Jordan
  . Sust.
> Matrices
  > Matrices como transf. lineales







Ej. → Perceptron $\quad \underline{w_1}x_1 + \underline{w_2}x_2 + \dots + b$



$\hat{y} \in \mathbb{R}$

Relu $\quad \max(0, x)$

$\hat{y} \in \{0, 1\}$

> Dimensiones no coinciden

Álgebra lineal

Propedéutico de la Maestría en Ciencia de Datos.
CUCEA, Universidad de Guadalajara. 2024B

Guadalajara, Jal. Junio de 2025

Reg Linéaire

$$\hat{y} = X\beta \in \mathbb{R}$$

$$X = \begin{pmatrix} \vdots & \\ x_{ij} & \\ \vdots & \end{pmatrix}; \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{pmatrix}$$

$$\mathcal{L} = \frac{1}{n} \sum (\hat{y}_i - y_i)^2$$

$$\boxed{\beta = (X^T X)^{-1} X^T y}$$

$$\frac{\partial \mathcal{L}}{\partial \beta} = X^T (\underbrace{X\beta}_{\hat{y}} - y)$$

Reg. Logistique

$$\hat{y} \in \{0, 1\}$$

$$P = \sigma(X\beta) = \frac{1}{1 + e^{-X\beta}}$$

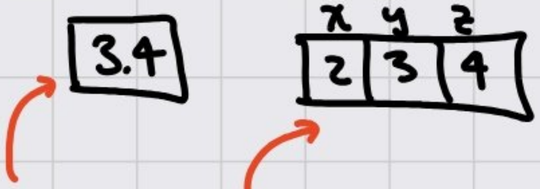
$$\mathcal{L} = -\sum y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)$$

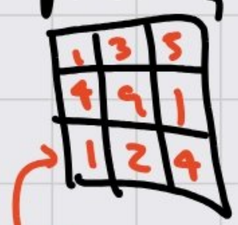
$$\frac{\partial \mathcal{L}}{\partial \beta} = X^T (\sigma(X\beta) - y)$$

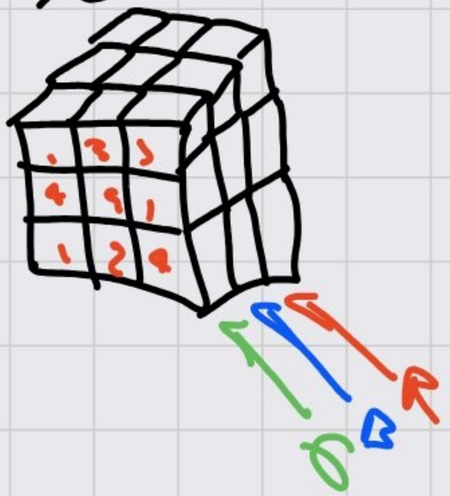
Tensor

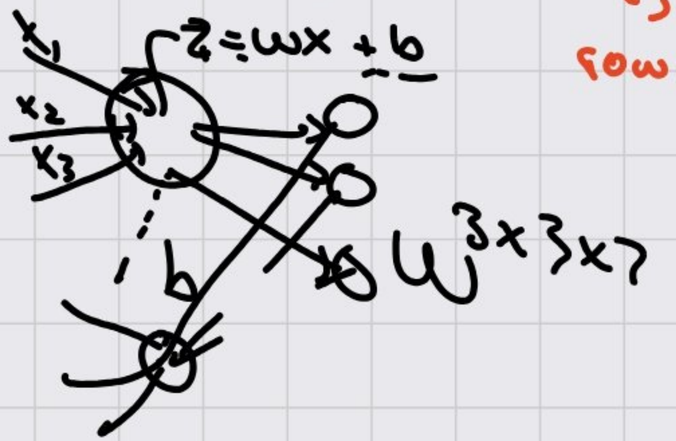
Orden: 0 escalar | 1 vector | 2 matriz | >3 tensor . . .

Ej.

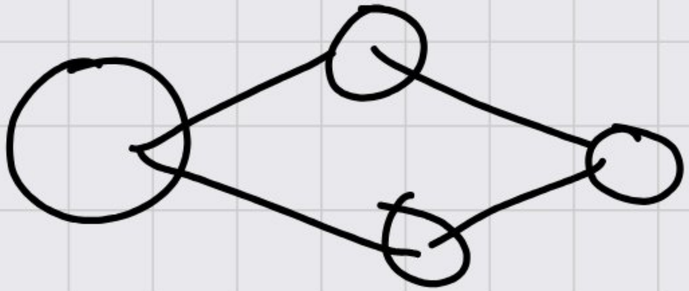


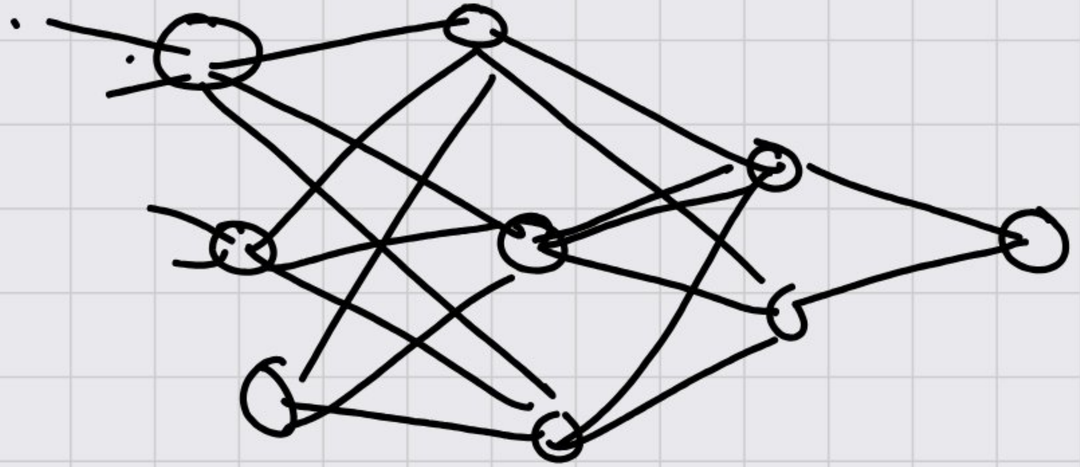








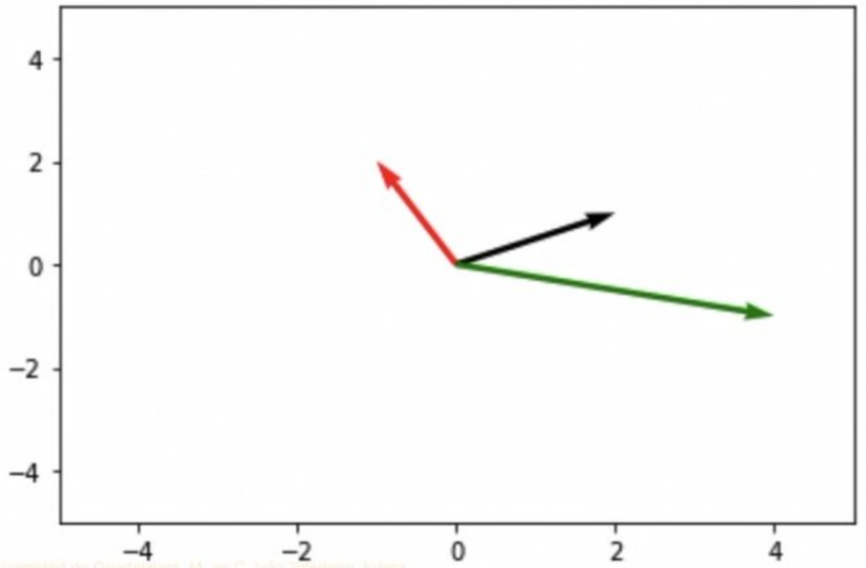




Operaciones de vectores

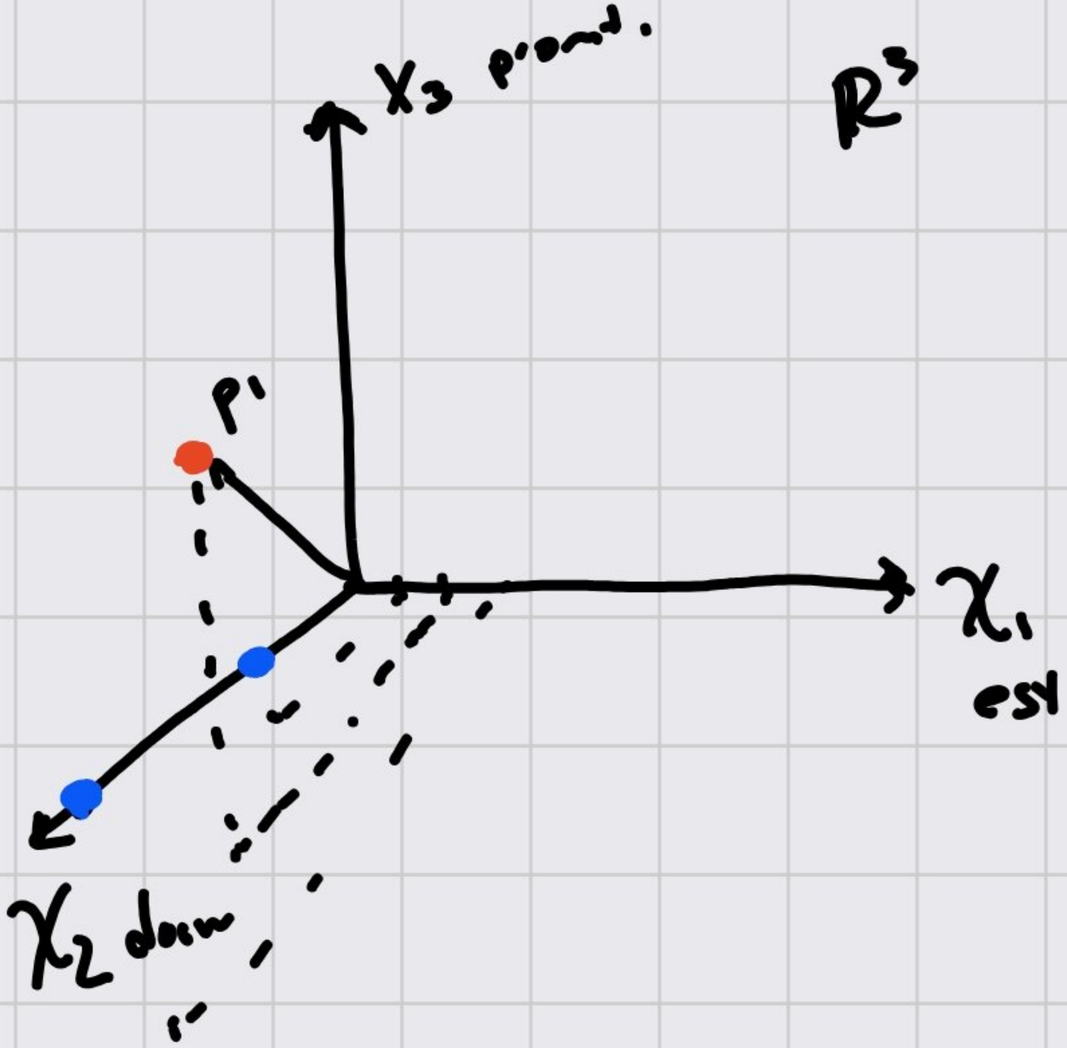
Definición

- Un vector es un arreglo de números ordenados. Son comúnmente utilizados para describir datos en un espacio multidimensional. Tienen una **magnitud** y **dirección.**
- Cada número define una coordinadas a lo largo de una dimensión en el espacio.
- $\begin{bmatrix} 2 \\ 1 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \end{bmatrix} \begin{bmatrix} 4 \\ -1 \end{bmatrix}$



Datos

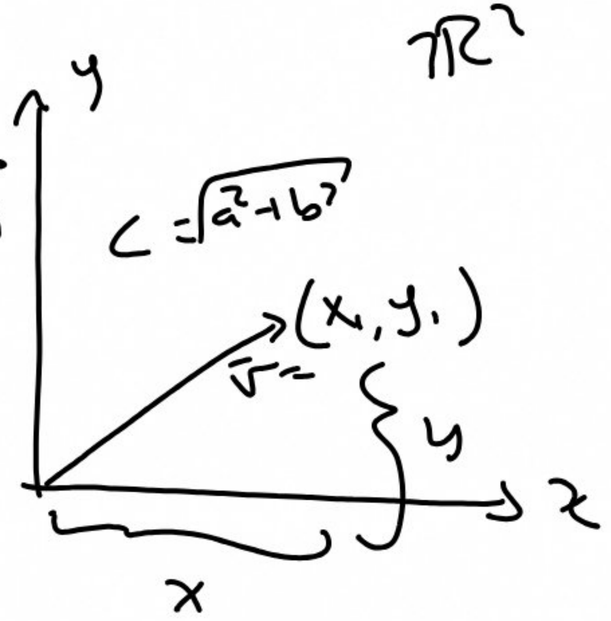
	X_1 esf.	X_2 dom	X_3 precio	$\vec{y}$ target Pos
P1 →	2	8	3	1
P2 →	1	6	0	0
P3 →	3	10	0	0
	⋮	⋮	⋮	⋮



Operaciones de vectores

Magnitud

$$|v| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2}$$

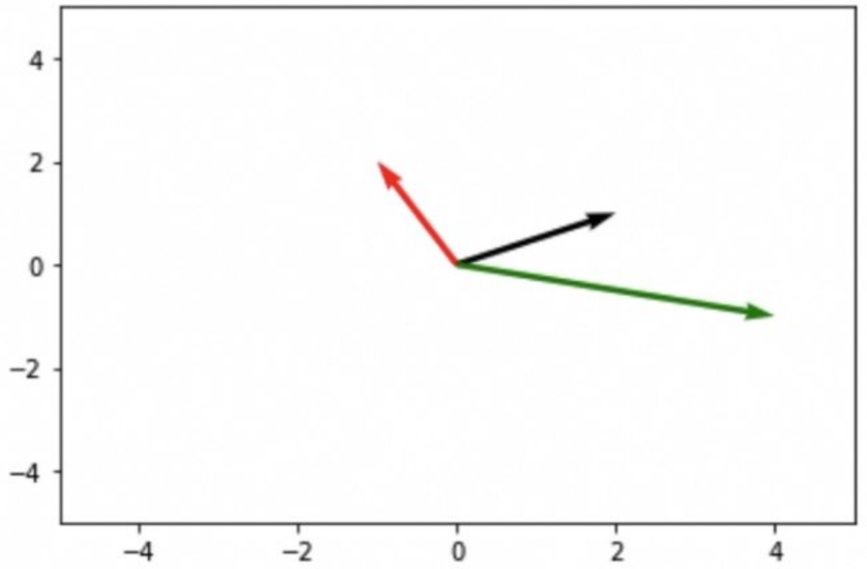


- Si un vector está dado por $\vec{v} = [v_1, v_2, \dots, v_n]$, la magnitud de un vector está dada por:
- $|\vec{v}| = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}$
- $\begin{bmatrix} 2 \\ 1 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \end{bmatrix} \begin{bmatrix} 4 \\ -1 \end{bmatrix}$

$$\sqrt{4^2 + (-1)^2} = \sqrt{17}$$

$$\sqrt{2^2 + 1^2} = \sqrt{5}$$

- Un **vector unitario** se define como un vector que va en la misma dirección que $\vec{v}$ pero que tiene magnitud 1. $\hat{v} = \dfrac{\vec{v}}{|\vec{v}|}$



Operaciones de vectores

Magnitud

- Si un vector está dado por $\vec{v} = [v_1, v_2, \ldots, v_n]$, la magnitud de un vector está dada por:
- $|\vec{v}| = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}$
- $\begin{bmatrix} 2 \\ 1 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \end{bmatrix} \begin{bmatrix} 4 \\ -1 \end{bmatrix}$

$$\sqrt{4^2 + (-1)^2} = \sqrt{17}$$

$$\sqrt{2^2 + 1^2} = \sqrt{5}$$

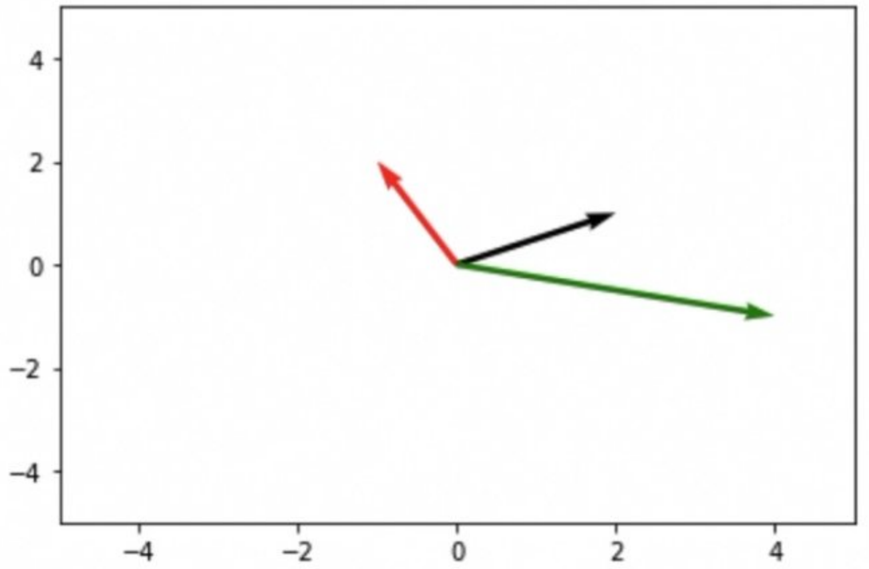
- Un **vector unitario** se define como un vector que va en la misma dirección que $\vec{v}$ pero que tiene magnitud 1. $\hat{v} = \dfrac{\vec{v}}{|\vec{v}|}$

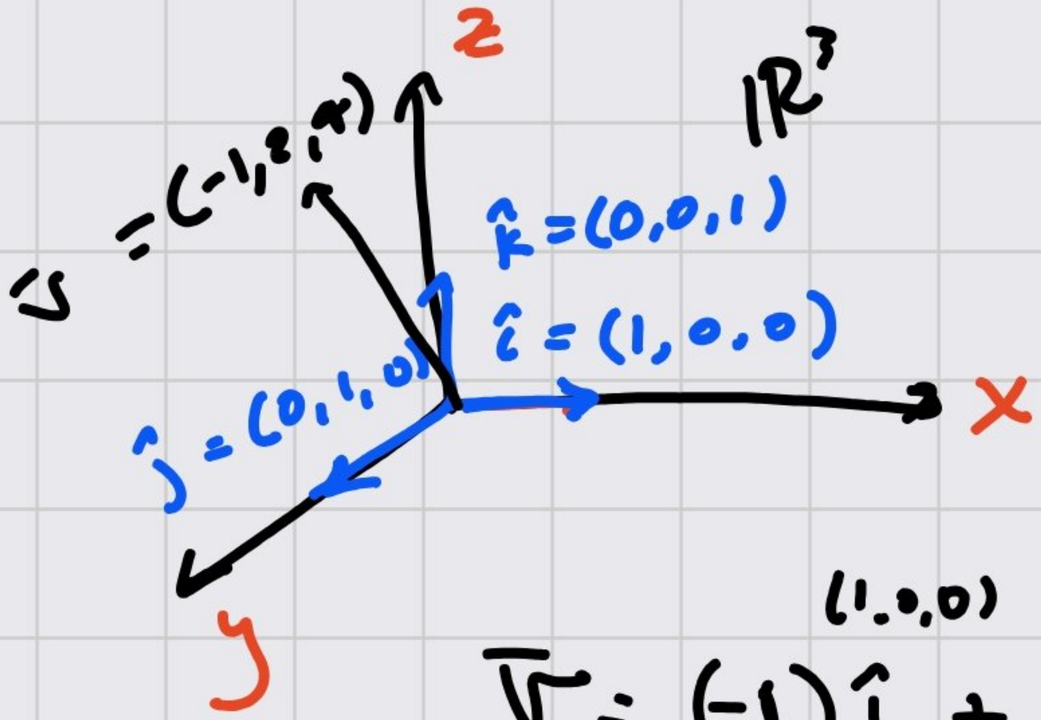
$\bar{v} = (1, 1, 1)$ vector

$|\bar{v}| = \sqrt{1^2 + 1^2 + 1^2} = \sqrt{3}$ escal.

$\hat{v} = \dfrac{\bar{v}}{|\bar{v}|} = \left(\frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}\right)$

magnitud — 1





$$\vec{v} = (-1)\hat{i} + (2)\hat{j} + (4)\hat{k}$$

$$= (-1,0,0) + (0,2,0) + (0,0,4) = (-1,2,4)$$

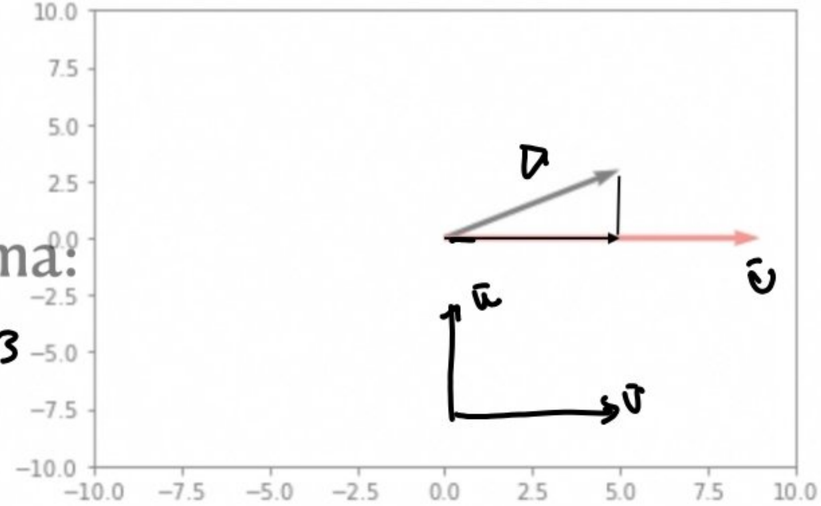
$\vec{v}$ es una comb. lineal de $\vec{i}, \vec{j}, \vec{k}$,

Operaciones con vectores

Producto punto

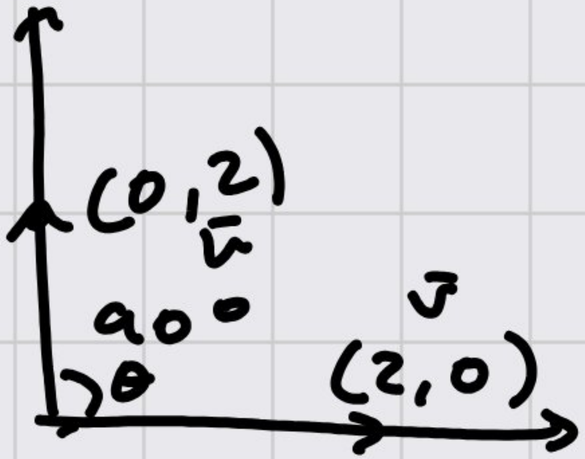
$$\vec{v} = [v_1, v_2, \ldots . v_n]$$

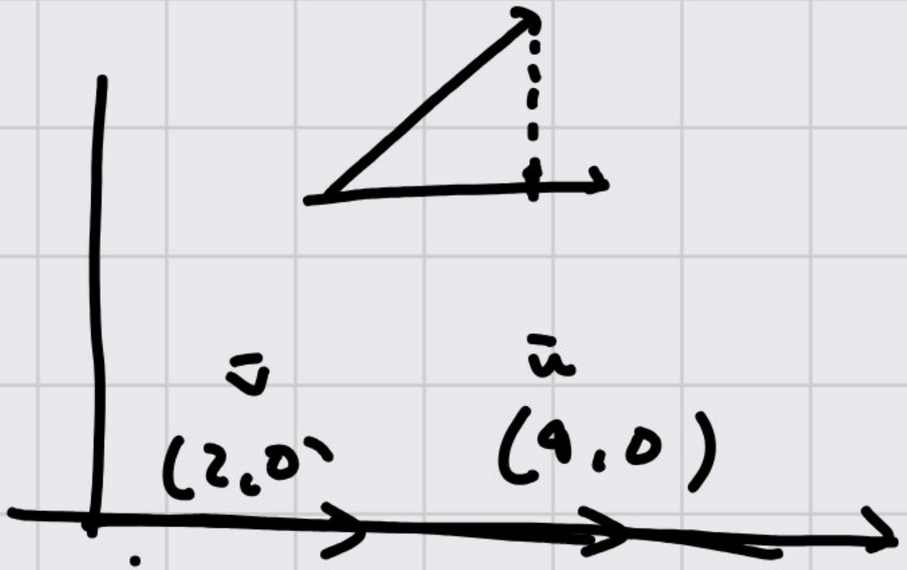
- El **producto punto** se calcula de la siguiente forma:
  $\bar{v} = (1,2,3)$; $\bar{u} = (2,3,4)$ ⇒ $\bar{v} \cdot \bar{u} = 1\cdot 2 + 3\cdot 2 + 9\cdot 3$
- $\vec{v} \cdot \vec{u} = v_1u_1 + v_2u_2 + \cdots + v_nu_n$ $= 2 + 6 + 12$
  $= 20$
  escalar
- Se tiene de salida un número escalar.




```
Producto punto = 45
```

- También puede calcularse mediante $\vec{v} \cdot \vec{u} = |\vec{v}||\vec{u}|\cos\theta$, utilizando el ángulo entre los dos vectores. En este sentido, un producto punto se puede ver como la proyección de un vector sobre otro.





$\bar{u}\cdot\bar{v} = 0\cdot 2 + 2\cdot 0 = 0$ $\quad\quad$ $\bar{u}\cdot\bar{v} = 8$

$=0$

$$\|v\|\|u\|\cos\theta = 2\cdot 2\cdot \underbrace{\cos 90^\circ}_{0}$$

) Correlaciones

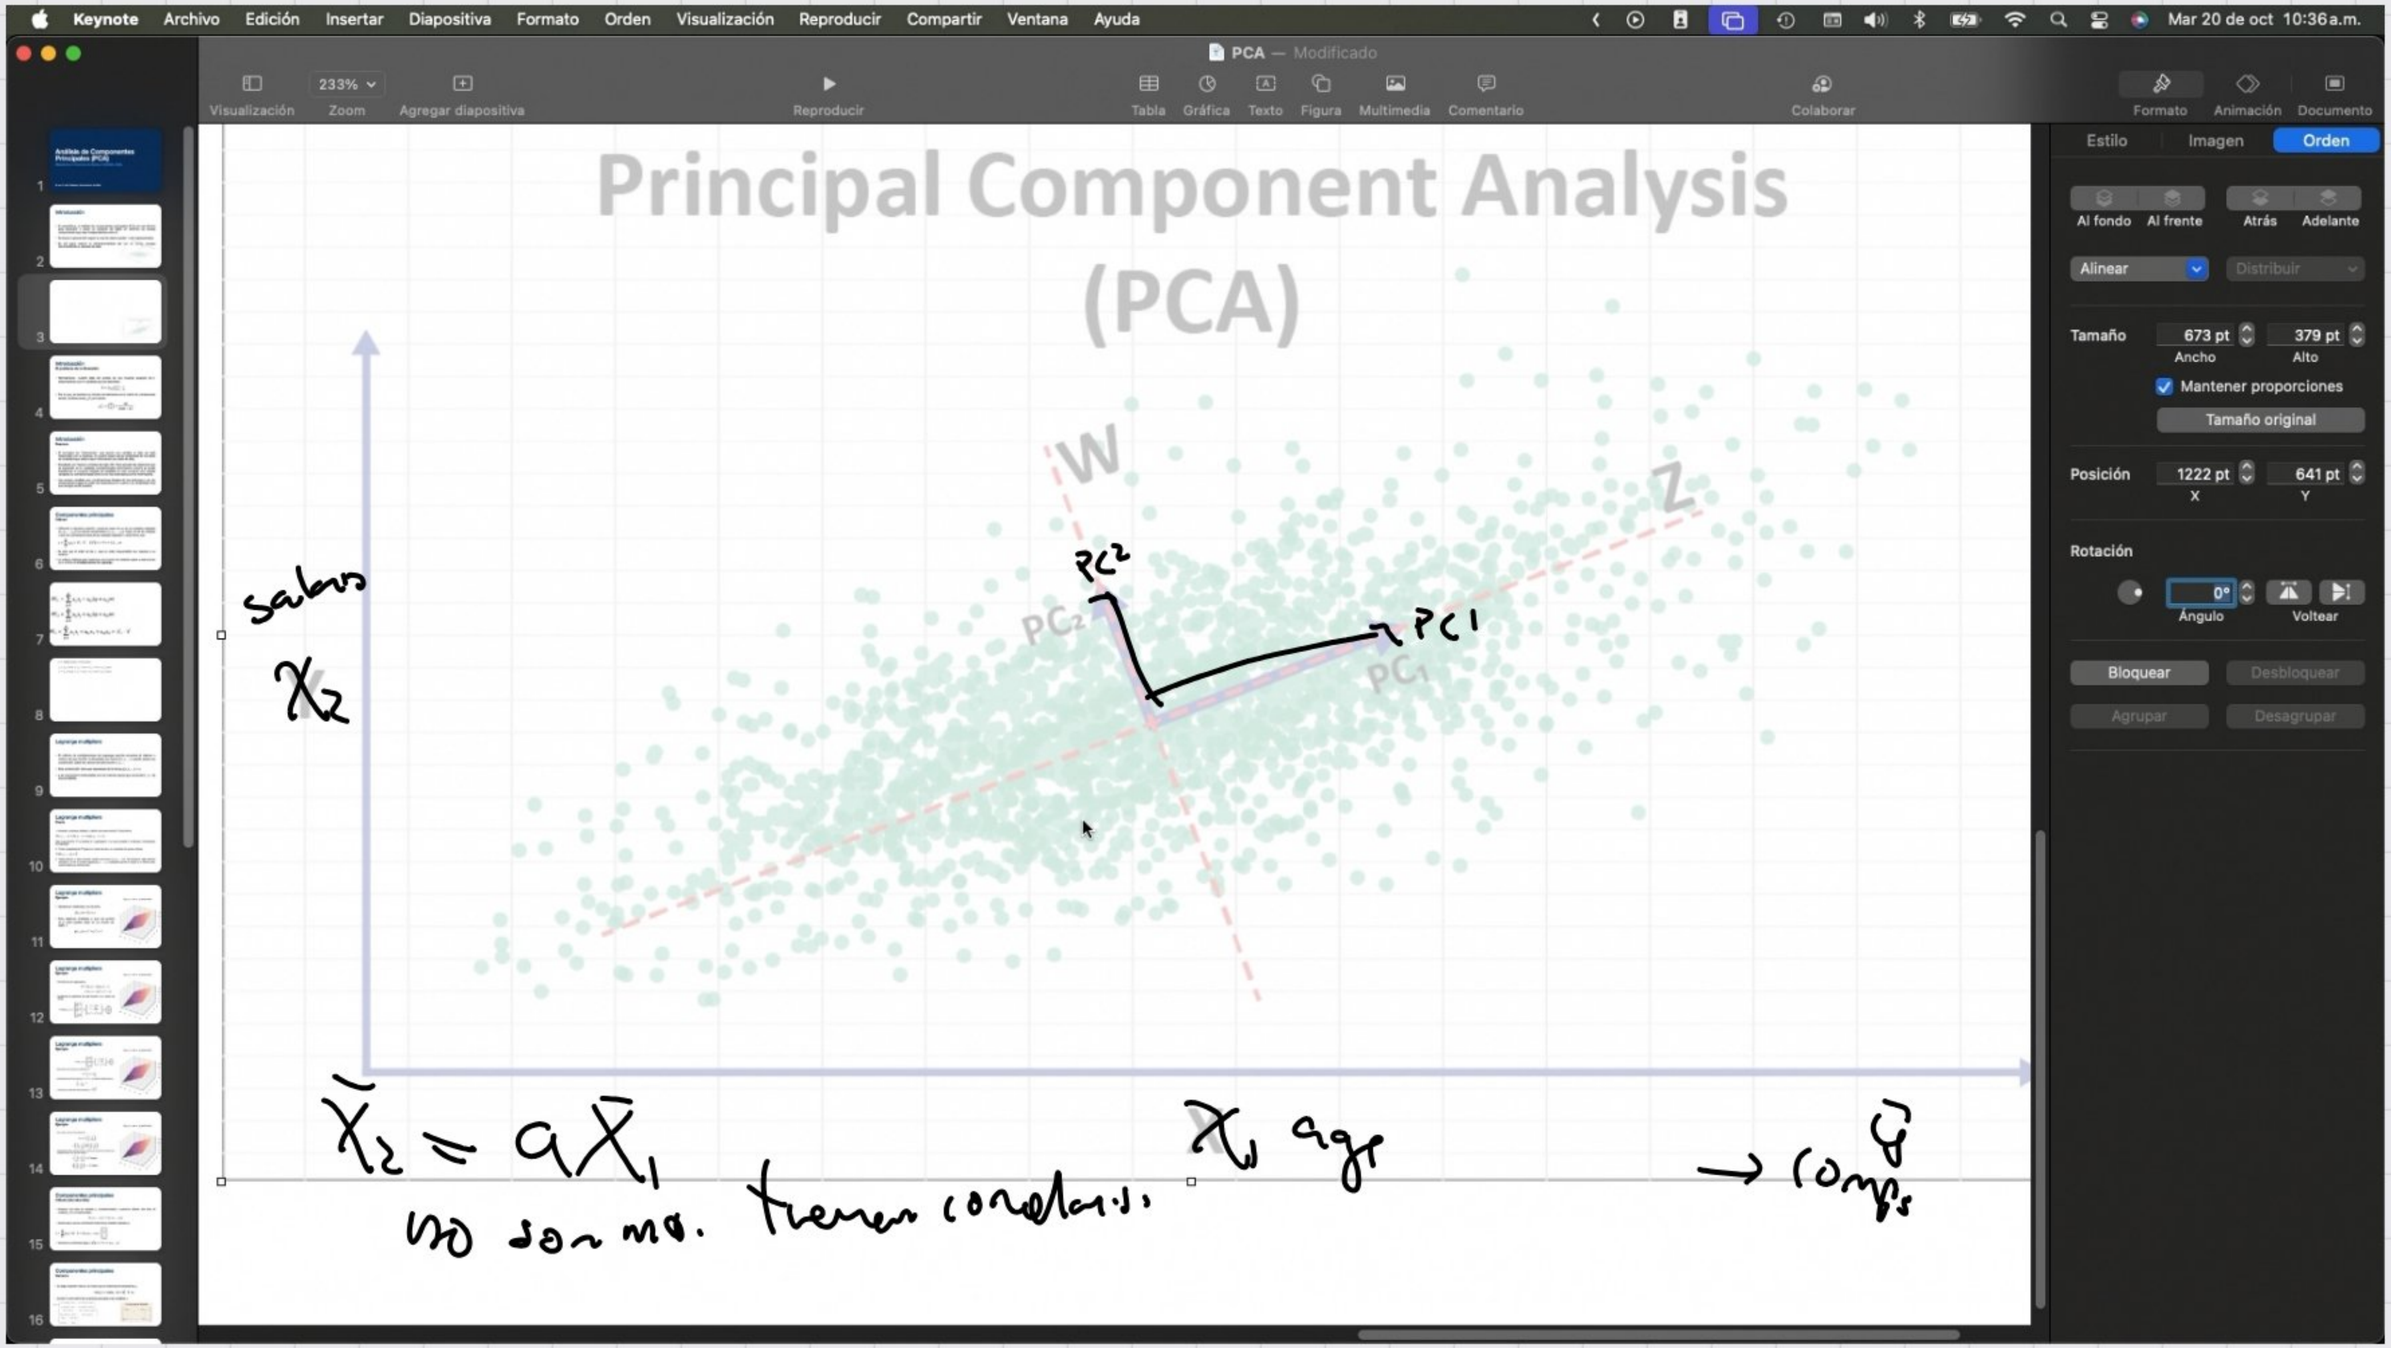
Independencia linear

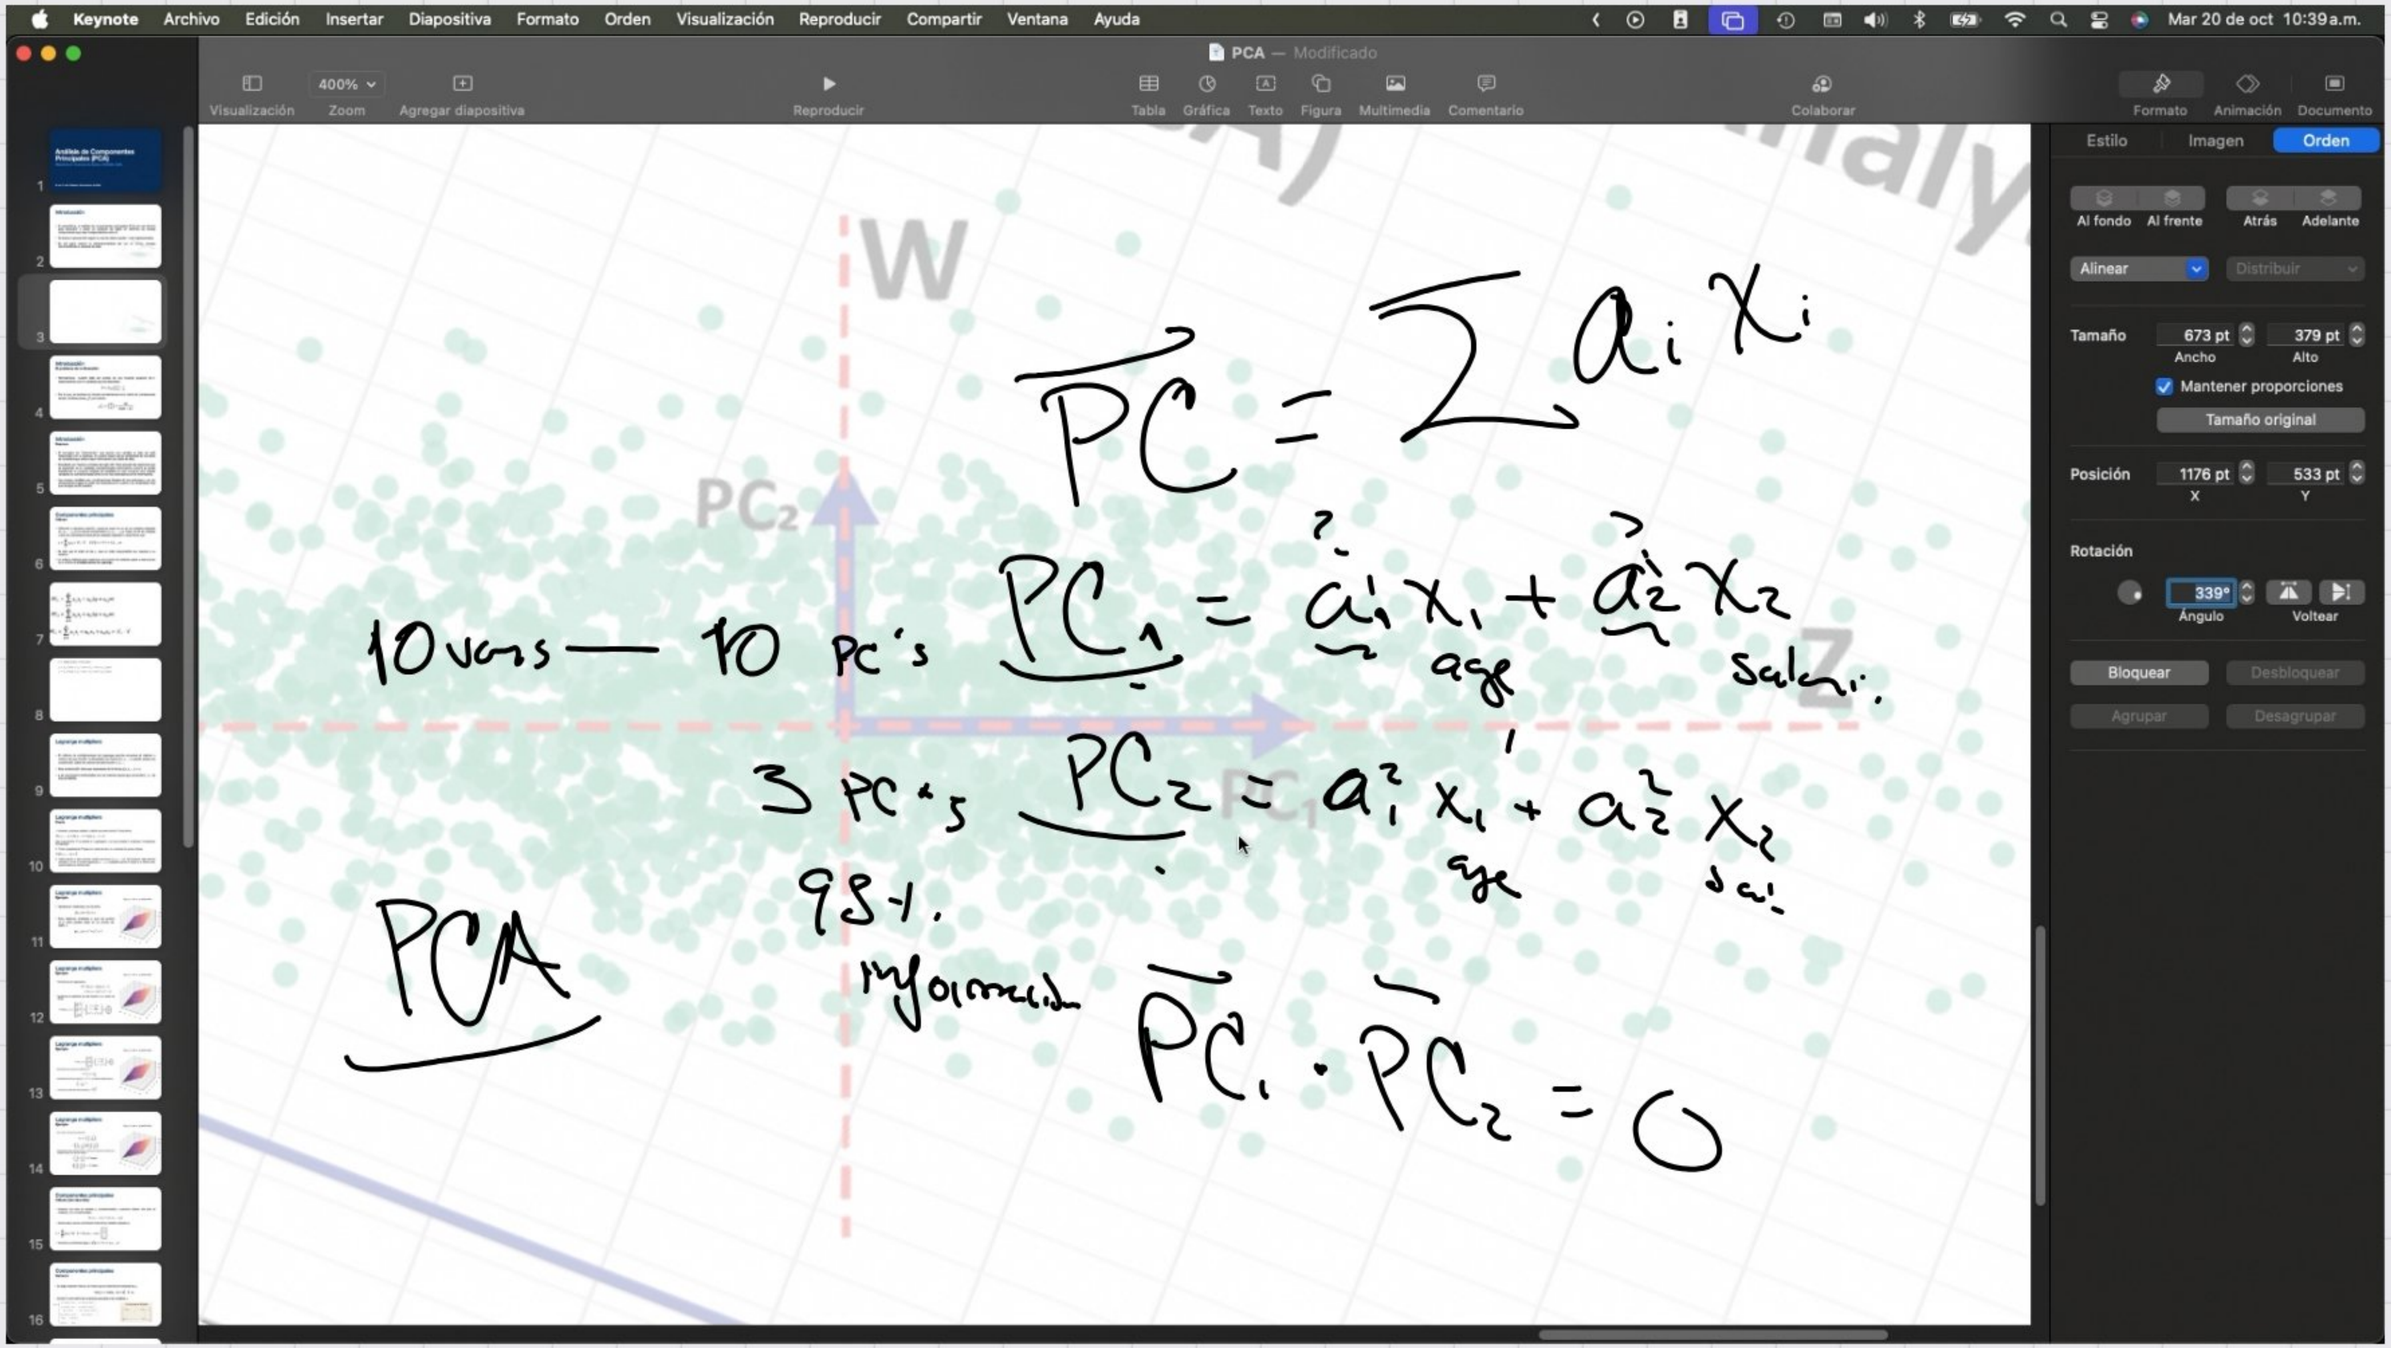
Definición

- Cuando un conjunto de vectores es **linearmente independiente,** no es posible representar un vector como una combinación lineal de los vectores restantes. Ejemplo: dos vectores ortogonales son linealmente independientes.
- Una **combinación lineal** de un vector es creada al combinar dos o más vectores a través de sumas o diferencias. Los vectores constituyentes pueden ser escalados por valores arbitrarios. Un vector $\vec{w}$ es una combinación lineal de $\vec{u}$ y $\vec{v}$ si se puede expresar de la siguiente forma:
- $\vec{w} = a\vec{u} + b\vec{v}$, siendo a y b números escalares.

$\vec{w}$ es una comb. lineal de dos vectores $\bar{u}, \bar{v}$

$$\vec{w} = a\bar{u} + b\bar{v}$$


Keynote Archivo Edición Insertar Diapositiva Formato Orden Visualización Reproducir Compartir Ventana Ayuda
Mar 20 de oct 10:36a.m.
PCA — Modificado
Visualización
Zoom
Agregar diapositiva
Reproducir
Tabla
Gráfica
Texto
Figura
Multimedia
Comentario
Colaborar
Formato
Animación
Documento
Estilo
Imagen
Orden
Al fondo
Al frente
Atrás
Adelante
Alinear
Distribuir
Tamaño
673 pt
Ancho
379 pt
Alto
Mantener proporciones
Tamaño original
Posición
1222 pt
X
641 pt
Y
Rotación
0°
Ángulo
Voltear
Bloquear
Desbloquear
Agrupar
Desagrupar
Principal Component Analysis
(PCA)
W
Z
PC2
PC1
PC2
PC1
salvo
$\tilde{X}_2 = q\tilde{X}_1$


PCA
10 vars — 10 PC's
3 PC's
95%
información
$\vec{PC} = \sum a_i x_i$
$PC_1 = a_1^1 x_1 + a_2^1 x_2$
$PC_2 = a_1^2 x_1 + a_2^2 x_2$
$\vec{PC_1} \cdot \vec{PC_2} = 0$
PC_2
PC_1