

• Resumen (Momentos Estadísticos)

①

> MEDIA

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i \quad \text{población}$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{muestra}$$

----- Dónde se concentran
"localización"

②

> VARIANZA

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad \text{pob.}$$

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2 \quad \text{muestra}$$

> DESVIACIÓN
ESTÁNDAR

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2} \quad \text{pob.}$$

$$s = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2} \quad \text{muestra}$$

----- Qué tanto varían
"dispersión"

③ > ASIMETRÍA
(SKEWNESS)

$$\frac{1}{s^3 n} \sum_{i=1}^n (x_i - \bar{x})^3$$

ASIMETRÍA FISHER


----- Simetría
Hacia qué lado se
extiende o está sesgada
la información

④ > CURTOSIS

$$\frac{1}{s^4 n} \sum_{i=1}^n (x_i - \bar{x})^4 - 3$$

----- "Forma"

Qué tan cerca de la
media.



ción

Para una población de n valores y un valor real $k > 1$, la proporción de valores dentro de k desviaciones estándar de la media es al menos $1 - \frac{1}{k^2}$.

$$1 - \frac{1}{k^2}$$

$$P(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Empirical Rule
(Normal Distributions)

VAR



μ, σ parámetros

Chebyshev's Inequality
(Any Distribution)

$$1 - \frac{1}{k^2}$$

$$P = 1 - \frac{1}{k^2}$$

$k > 1$
desviaciones
estándar



$$1 - \frac{1}{5^2}$$

$$1 - \frac{1}{25} = \frac{24}{25} \approx 96\%$$

VARIANZA

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

$$s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

"Dispersión"

$$\sigma_{xy} = \frac{1}{N} \sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)$$

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

COVARIANZA


"Relación LINEAL
entre variables"

Datos bivariados

Diagrama de dispersión

- Datos Bivariados es simplemente cuando comparamos dos variables diferentes.
- Por convención, el eje x se fija como la variable independiente.
- Se fija el eje y como variable dependiente, aquella que se mide relativa a x.
- Una técnica gráfica que se usa para mostrar la relación entre variables es llamada diagrama de dispersión.
- En esta, puntos (x,y) (observaciones) son graficados.

Normalmente, las dos variables están relacionada



Datos bivariados

Covarianza

- Una forma común de comparar dos variables es comparando sus variantes-qué tan lejos está cada valor de su media correspondiente.
- La covarianza de una población, aunque usando la notación de la media de muestra, definida por:

$$\text{cov}(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_i y_i - \bar{x} \bar{y}$$

Handwritten notes in red:
- Above the first sum: Ky
- Above the second sum: cm
- Under the first sum: $Alg \cdot cm$

Datos bivariados

Factor de correlación de Pearson


- Para solucionar el problema de las unidades, normalizamos los valores que vienen de dos distribuciones distintas y definimos el factor de correlación de Pearson.

$$\rho_{x,y} = \frac{\overset{\text{Kg} \cdot \text{cm}}{\text{cov}(x, y)}}{\underset{\substack{\text{Kg} \quad \text{cm}}{\sigma_x \sigma_y}}{=}} = \frac{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{\sum_{i=1}^N (x_i - \bar{x})^2}{N}} \sqrt{\frac{\sum_{i=1}^N (y_i - \bar{y})^2}{N}}} = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}}$$


Los valores del factor de correlación caen entre -1 y 1.

- =1 Significa una correlación total positiva.
- = 0 Significa que no existe una correlación lineal.
- = -1 Significa una correlación total negativa.

Handwritten notes:
- $\rho_{x,y}$ is circled in purple.
- A purple arrow points from $\rho_{x,y}$ to the word "LINEAL" which is circled in purple.
- The word "LINEAL" is written in purple.
- The word "adimensional" is written in orange above "LINEAL".
- The words "corr. Pearson" are written in purple to the left of "LINEAL".



performance



$$r_{xy} = \frac{\text{cov}_{xy}}{\sigma_x \sigma_y}$$

$i=1$

x^{sueto}	$y^{\text{perf.}}$
6	6
4	3
5	7
8	2
7	10

$i=2$

$i=3$


$\vdots$

Rank X	Rank Y
3	3
1	2
2	4
5	1
4	5

Spearman

Spearman's Rank Correlation Coefficient

$$\rho = \frac{\sum_{i=1}^n (R(x_i) - \overline{R(x)})(R(y_i) - \overline{R(y)})}{\sqrt{\sum_{i=1}^n (R(x_i) - \overline{R(x)})^2 \cdot \sum_{i=1}^n (R(y_i) - \overline{R(y)})^2}} = 1 - \frac{6 \sum_{i=1}^n (R(x_i) - \overline{R(x)})(R(y_i) - \overline{R(y)})}{n(n^2 - 1)}$$



Where, $R(x_i)$ = rank of x_i



$R(y_i)$ = rank of y_i

$\overline{R(x)}$ = mean rank of x

$\overline{R(y)}$ = mean rank of y

n = number of pairs

```
plt1 = sns.boxplot(x=df_advertising['TV'], ax = axs[0])
plt2 = sns.boxplot(x=df_advertising['Newspaper'], ax = axs[1])
plt3 = sns.boxplot(x=df_advertising['Radio'], ax = axs[2])
plt.tight_layout()
```



valores atipicos

